

Copiloto de Operaciones Cloud con cifras verificadas

Consultas en lenguaje natural sobre inventario, respaldos y costos de una nube, sin cifras inventadas

Estudiante: Hans Berrocal Carranza Docente: Andrés Felipe Rojas Parra Programa: Certified AI/LLM Solution Architect · BSG Institute
Fecha: 22/09/2026

1. Problema

Los equipos que operan nubes empresariales responden a diario preguntas como «¿qué servidores de producción no tienen respaldo y cuánto cuestan?». La respuesta está repartida entre inventarios, reportes de respaldo y reportes de costos de decenas de hojas. Un LLM que contesta «de memoria» sobre estos datos es un riesgo: una cifra inventada en un reporte de costos o de auditoría tiene consecuencias reales, el mismo patrón de **Mata v. Avianca** visto en la Sesión 4.

2. Solución y arquitectura

La base de conocimiento son **datos estructurados** de operación cloud, por lo que el grounding se implementa con **tool calling**: el LLM decide qué consultar y redacta, pero **nunca calcula**, y las cifras las producen tools de solo lectura que devuelven solo las filas relevantes. La misma pregunta puede enviarse **con y sin grounding** para demostrar el efecto. Antes de responder, una **heurística propia** (verificador de procedencia) comprueba que cada número, fecha y recurso de la respuesta provenga de los resultados de las tools, admite derivados que puede recalcular y marca el resto. Proveedores: **Ollama local** y una API en la nube detrás de la misma interfaz.

1. Interfaz React 18 + Vite	2. API FastAPI · límites de longitud · keys en .env	3. Generación Orquestador con tool calling · modo con / sin grounding	4. Recuperación Tools tipadas (Pydantic), solo lectura, filas relevantes	5. Datos SQLite sintética	6. Heurística propia Verificador de procedencia de cifras y recursos
---------------------------------------	---	---	--	-------------------------------------	--

3. Datos: 100 % sintéticos y reproducibles

Generador propio (Python, sin dependencias, determinista por semilla) de un tenancy OCI **ficticio** con el mismo modelo de datos que las herramientas de inventario y FinOps que uso profesionalmente: 120 instancias, 240 discos, 15 bases de datos, reglas de red, buckets y 3 meses de costos diarios (~83 mil filas), todo consistente entre sí. Incluye:

- **Hallazgos sembrados**: instancia GPU detenida que sigue facturando, discos sin respaldo, backups huérfanos, reglas expuestas a internet, bucket público y un pico de costos.
- **Golden set de 32 preguntas** con respuesta calculada desde los datos, incluidas preguntas sin datos, fuera de dominio y de rechazo.
- **8 casos adversariales** diseñados para engañar a la heurística y **3 de inyección indirecta** escondidos en tags y descripciones.

No se usa ningún dato de clientes reales, así que el repositorio y el video se pueden publicar.

4. Mapeo a la rúbrica de la Opción 02

Criterio del curso	Pts	Cómo lo cubre el proyecto
Funcionalidad y código	30	Endpoint con modo con y sin grounding para la misma pregunta. Manejo consistente de preguntas fuera de la base (sin datos, fuera de dominio, rechazo). README reproducible y MODO_SIMULADO si falta una API key.
Seguridad y arquitectura	20	API keys solo en .env, con gitleaks en pre-commit y CI. Recuperación (tools) separada de generación (orquestador). Límites configurados de longitud de respuesta, temperatura e iteraciones. Extras: rate limit y token canario.
Grounding + heurística anti-alucinación	25	Efecto medido sobre 32 preguntas con y sin grounding (3 corridas). Verificador de procedencia de 4 capas, más allá del regex de clase, probado contra 8 casos adversariales con tasa de detección y de falsos positivos.
Documentación	10	Límites documentados con honestidad: casos que engañan a la heurística y preguntas que siguen siendo riesgosas aun con grounding.
Video (≤ 30 min)	15	En vivo: la misma pregunta con y sin grounding, la alerta disparada, un caso que falló y qué se aprendió de él.

5. Criterios de éxito medibles

- Al menos un caso reproducible en que el modo sin grounding inventa una cifra convincente, y la heurística lo detecta.
- Heurística: detección ≥ 90 % de cifras no respaldadas y ≤ 10 % de falsos positivos; ninguna respuesta fuera de la base sin marcar.
- Al menos 5 pares con y sin grounding documentados (se entregan los 32), incluida la tasa de falso «no sé».

6. Alcance

Se evalúa con la rúbrica de la **Opción 02**, con aportes de la **03** (validación Pydantic de las llamadas a tools, reintentos con límite) y la **04** (controles OWASP puntuales). **No incluye** conexión en vivo a una nube real, acciones de escritura ni una segunda API en la nube; quedan como evolución para los módulos siguientes del programa.

Base de evaluación acordada con el docente: Opción 02 (22/09/2026). Entrega estimada: 04/10/2026.